

國立中央大學

資訊工程研究所

碩士論文

利用深度學習檢測震前電離層異常

Using deep learning to detect pre-earthquake ionospheric
anomalies

研究生：郭家暉

指導教授：陳映濃 博士

中華民國一百一十二年六月

國立中央大學圖書館學位論文授權書

2019.9 版

填單日期：112/7/27

授權人姓名	郭家暉	學號	110522152
系所名稱	資訊工程學系	學位類別	<input checked="" type="checkbox"/> 碩士 <input type="checkbox"/> 博士
論文名稱	利用深度學習檢測震前電離層異常	指導教授	陳映濃

學位論文網路公開授權

授權本人撰寫之學位論文全文電子檔：

- 在「國立中央大學圖書館博碩士論文系統」
 - (☒) 同意立即網路公開
 - () 同意 於西元_____年_____月_____日網路公開
 - () 不同意網路公開，原因是：_____
- 在國家圖書館「臺灣博碩士論文知識加值系統」
 - (☒) 同意立即網路公開
 - () 同意 於西元_____年_____月_____日網路公開
 - () 不同意網路公開，原因是：_____

依著作權法規定，非專屬、無償授權國立中央大學、台灣聯合大學系統與國家圖書館，不限地域、時間與次數，以文件、錄影帶、錄音帶、光碟、微縮、數位化或其他方式將上列授權標的基於非營利目的進行重製。

學位論文紙本延後公開申請 (紙本學位論文立即公開者此欄免填)

本人撰寫之學位論文紙本因以下原因將延後公開

- 延後原因
 - () 已申請專利並檢附證明，專利申請案號：_____
 - () 準備以上列論文投稿期刊
 - () 涉國家機密
 - () 依法不得提供，請說明：_____

• 公開日期：西元_____年_____月_____日

※繳交教務處註冊組之紙本論文(送繳國家圖書館)若不立即公開，請加填「國家圖書館學位論文延後公開申請書」

研究生簽名：郭家暉

指導教授簽名：陳映濃

*本授權書請完整填寫並親筆簽名後，裝訂於論文封面之次頁。

國立中央大學碩士班研究生 論文指導教授推薦書

資訊工程學系碩士班 學系/研究所 郭家暉 研究生
所提之論文 利用深度學習檢測震前電離層異常
係由本人指導撰述，同意提付審查。

指導教授 陳映濃 (簽章)
112 年 7 月 28 日

1120728

國立中央大學碩士班研究生 論文口試委員審定書

資訊工程學系碩士班 學系/研究所 郭家暉 研究生
所提之論文 利用深度學習檢測震前電離層異常
經由委員會審議，認定符合碩士資格標準。

學位考試委員會召集人

委

員

莊 啓 宏

林 建 宏

陳 映 濃

中 華 民 國

112 年 7 月 5 日

摘要

本篇論文使用深度學習模型 ConvLSTM 來預測具有震前電離層異常之地震，使用的資料為 GIMTEC 公開資料。有別於地震預警系統只能在地震發生前幾秒或是幾分鐘才能收到通知，對於地震發生前的準備，明顯是時間不足的，如果能早在前一天甚至是數天前掌握地震即將到來的資訊，便可以及早預防、疏散，才能夠大幅度減少地震所帶來的災害。為了預測出那些具有明顯的地震電離層異常之規模 6 以上的地震，有別於使用傳統 LSTM 模型，本篇論文使用之 ConvLSTM 模型能夠獲得數值圖象二維空間的訊息，相較於 LSTM，ConvLSTM 模型能夠更大的利用相鄰幾天的資訊來訓練模型，並得到更可靠的結果。

Abstract

In this paper, we use the deep learning model ConvLSTM to detect earthquakes with pre-seismic ionospheric anomalies, using the publicly available GIMTEC data. Unlike earthquake early warning systems that can only receive notifications a few seconds or minutes before an earthquake occurs, it is obviously that there is insufficient time for preparation before an earthquake. If we can obtain information about an impending earthquake a day or even several days in advance, we can take early preventive measures and evacuation, thus significantly reducing the disasters caused by earthquakes. In order to predict earthquakes of magnitude 6 or above with significant ionospheric anomalies, this paper utilizes the ConvLSTM model instead of the traditional LSTM model. The ConvLSTM model can capture spatial information in two-dimensional numerical images, enabling it to better utilize information from adjacent days for training and obtain more reliable results compared to LSTM.

目錄

摘要	I
ABSTRACT	II
目錄	III
圖目錄	IV
表目錄	V
第一章 緒論.....	1
1-1 研究動機	1
1-2 地震電離層前兆	2
1-3 相關文獻啟發	3
第二章 模型設計與細節	6
2-1 CONVLSTM 介紹.....	6
2-2 模型架構設計(MODEL ARCHITECTURE DESIGN).....	8
第三章 資料與地震判定	10
3-1 GIMTEC 資料.....	10
3-2 電離層異常判定	11
3-3 有地震、無地震的界定.....	13
第四章 實驗結果與討論	16
4-1 訓練資料、測試資料介紹.....	16
4-2 實驗說明	18
4-3 異常判斷指標	20
4-4 實驗結果	22
第五章 結論.....	28
參考文獻	29

圖目錄

圖 1: Sliding Window Concept(引用自 Tsai et al.(2022))...	4
圖 2: 本篇論文所使用之模型架構.....	8
圖 3: TEC 範例圖	11
圖 4: 自 1999 年 1 月 1 日至 2021 年 12 月 31 日所有規模大於 6 且有震前電離層異常的地震.....	14
圖 5: 所有地震資料對應時間之分布圖	15
圖 6: 所有無地震資料對應時間之分布圖	15
圖 7: 所有無地震訓練資料對應時間之分布圖(實驗 1).....	17
圖 8: 所有無地震測試資料對應時間之分布圖(實驗 1).....	17
圖 9: 所有地震測試資料對應時間之分布圖(實驗 1).....	18
圖 10: 模型訓練 Loss 對應 Epoch 圖(實驗 1)	19
圖 11: 2000 年 7 月 20 日之地震測試資料結果圖.....	27
圖 12: 2000 年 6 月之 Final Dst Index 數值圖.....	27

表目錄

表 1: 使用本篇論文模型架構分別獨立訓練 10 次的測試 實驗結果.....	24
表 2: 對應實驗結果 1(Experiment 1)之 20 筆地震測試資 料預測結果.....	25
表 3: 對應實驗結果 1(Experiment 1)之 20 筆無地震測試 資料預測結果.....	26

第一章 緒論

1-1 研究動機

台灣位於環太平洋地震帶，由於位於歐亞板塊和菲律賓板塊交界處，這兩個板塊之間的碰撞和滑動引起了大量的地震活動，以致於台灣是一個地震非常活躍的區域。台灣經常發生中小規模的地震，包括許多有感的地震，其中不乏大規模的地震，造成大量人員傷亡和財產損失。舉例來說，1999 年的 921 地震(規模 7.3)，造成大量傷亡，對台灣的經濟和建設造成嚴重的打擊。因此地震對台灣有著密不可分的影響，對地震的預防和預測能力都是必須的，然而預防的部分，全球各個國家都有自己的一套地震預警系統，而台灣地震研究機構（中央氣象局）負責監測和研究地震活動，提供地震相關的資訊和警報，以幫助減少地震可能帶來的損害。研究日本地震有助於將其應用在台灣地震上，因為台灣和日本有著相似的地質條件和地震活動模式，相較於台灣，日本擁有豐富的地震資料，如果能透過深度學習的方法有效的預測日本地震，有助於日後將其應用在預測台灣地震上。

地震預警系統 (Earthquake Early Warning System) 是指利用地震波來偵測地震，其中 P 波相較於 S 波，其傳播速度較快，透過分析分布在各

地的即時傳輸地震監測站的資料，對其分析評估，藉此發布警報避免人員傷亡。雖然地震預警系統能早在地震波來臨前數秒通知人民，但實際上針對當下處於不同狀況的人，可能還是會有一大部分人是沒辦法及時地做出反應，如果能透過其他方法來預測地震，能早在地震發生的前一天(甚至數日前)就能預測到的話，無疑能對即將到來的災害做出最完善的準備並將損害降至最低。

1-2 地震電離層前兆

地球大氣層最下面的一層是對流層，它從地面延伸到約 10 公里的高處。10 公里以上為平流層，再向上為中間層。在約 80 公里以上的增溫層大氣已經非常稀薄，在這裡陽光中的紫外線和 X 射線可以使得空氣分子電離，自由的電子在與正電荷的離子合併前可以短暫地自由活動，這樣在這個高度造成電漿體。在這裡自由電子的數量足以影響電波的傳播。

其中全電子含量(Total Electron Content, TEC)是一種衡量大氣中電離層的電子含量和分佈的指標，TEC 的數值可以通過測量從地球上層大氣到衛星高度範圍內的無線電訊號在電離層中的傳播延遲來獲得。這種測量方法由全球定位系統（如 GPS）上的接受器進行，藉以研究大氣中的電

離層活動，包括太陽活動對電離層的影響、電離層電子密度變化，以及大氣中的電離層擾動等。電離層與地震之間存在著密切的關係，因為地震可能會對電離層產生影響，進而導致電離層前兆現象。這也本篇論文的研究對象，透過電離層來研究地震與電離層的關係，透過深度學習的方法藉由預測正常的觀測 TEC 值。

首先，直接的影響如地震發生時，地震波會在地球內部傳播，並可能產生大量的能量，包括高能粒子和電磁波，這些能量可能會激發電離層中的離子，使其產生游離現象，導致電離層中的離子密度增加，並引起電離層的不穩定性和變化。然而這種直接的影響對地震通常是短暫的，持續時間可能只有幾分鐘到幾小時。其次，地震也可能產生間接的影響，即地震電離層前兆現象，地震在發生前，地殼中的應力變化可能會引起地震前兆，包括在電離層中產生的變化。例如，地震在發生前的數分鐘至數天內，地震震源附近的電離層中出現的電場變化，導致電離層中 TEC 的變化。

1-3 相關文獻啟發

本篇論文受到 Tsai et al.(2022)的啟發，他們使用 GIMTEC 的資料，以及其他 feature 如地磁指數 (geomagnetic index Dst)、太陽活動指數

(solar activity F10.7)、太陽黑子數 (sunspot number, SSN)、太陽發射指數 (solar emission index Lyman- α)，並使用深度學習方法，利用 LSTM model 訓練時序資料，以預測未來時間之資料，他們使用的窗口大小為 7 天 (168 小時)，藉此預測下一個小時 (第 169 小時) 的資料，如圖 1 所示。其他還有使用 Ensemble Learning 挑出最佳的前三名 model 作為測試模型，並且採用多數決 (majority vote) 來作為最後判斷。每個模型預測結果以 Relative Error 來做區分，並制定一個門檻值 (threshold)，得到最終之結果。




圖 1: Sliding Window Concept(引用自 Tsai et al.(2022))

其他利用深度學習方法運用在 TEC 與地震關係的文獻還有 Bernadus Anggo Seno Aji et al.(2017)，利用多層感知器(Multilayer Perceptron, MLP)模型去計算 TEC 變化量，得出 觀測值-預測值 之差異圖，並得出地震可能的發生點與時間。更值得一提的是，Bernadus Anggo Seno Aji 也表

明就算在地磁沒有明顯干擾的情況下電離層也可能會有不正常的變化，然而這種情況是有很多種解釋的。故機器學習與深度學習之方法相較於古典統計方法，更有機會去探測出這些不確定因素。

第二章 模型設計與細節

2-1 ConvLSTM 介紹

介紹 ConvLSTM 之前，得先介紹 LSTM (Long Short-Term Memory)，它是一種在循環神經網路 (Recurrent Neural Network) 中被廣泛使用的模型，在現今提到只要提到 RNN，其實都是指 LSTM，它能夠處理長序列的輸入和輸出。在 LSTM 中主要有輸入門(Input gate)、遺忘門(Forget gate)、輸出門(Output gate)、記憶單元(Cell Memory)，其中 Cell Memory 是此模型的核心部分，它負責記憶狀態並決定哪些訊息需要保留或忘記。而 Input gate 和 Forget gate 則控制哪些訊息進入或離開記憶單元，最後 Output gate 則決定哪些訊息需要作為輸出。

$$i_t = \sigma(W_{ix}x_t + W_{im}m_{t-1} + W_{ic}c_{t-1} + b_i) \quad (1)$$

$$f_t = \sigma(W_{fx}x_t + W_{fm}m_{t-1} + W_{fc}c_{t-1} + b_f) \quad (2)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot g(W_{cx}x_t + W_{cm}m_{t-1} + b_c) \quad (3)$$

$$o_t = \sigma(W_{ox}x_t + W_{om}m_{t-1} + W_{oc}c_t + b_o) \quad (4)$$

$$m_t = o_t \odot h(c_t) \quad (5)$$

$$y_t = \phi(W_{ym}m_t + b_y) \quad (6)$$

其中 $x=(x_1,\dots,x_T), y=(y_1,\dots,y_T)$ 為 LSTM model 之 input sequence 和 output sequence，對應時間 $t=1$ to T 。而 W (weight matrices) 包含了 W_{ic} 、 W_{fc} 、 W_{oc} ，皆為對角權重矩陣 (diagonal weight matrices)，目的是為了使用 Peephole connections， b 則為 bias vector，另外採用之 σ 為 logistic sigmoid function、 g 和 h 為 \tanh 、 ϕ 則視任務最後輸出決定，可以使用 *softmax function*。

ConvLSTM 是一種結合了 LSTM 和 CNN 的模型，用於處理有時間序列和空間性質的數據，如影片、遙感圖像等。ConvLSTM 對於 LSTM 而言，就是多了處理空間訊息。具體來說，就是將原本的全連接層(Fully Connected Layer)改用卷積層(Convolutional Layer)，以處理像是圖片之空間資料。所以概念上 FullyConnected-LSTM 可以稱做是 ConvLSTM 的一種 special case。

本篇論文使用 ConvLSTM model 來預測選定日子的前 30 日每小時 TEC 值，相較於 Tsai et al.(2022)使用的 LSTM model，只考慮了時間序列的概念，我們多考慮了空間的概念，因為 Convolutional 的 kernel 利用滑動窗口(sliding window)的概念，能利用除了選定點之前的訊息，還能考慮相鄰時間、日子之訊息，也就是空間訊息來預測未來時間的 TEC 值。

2-2 模型架構設計(Model Architecture design)

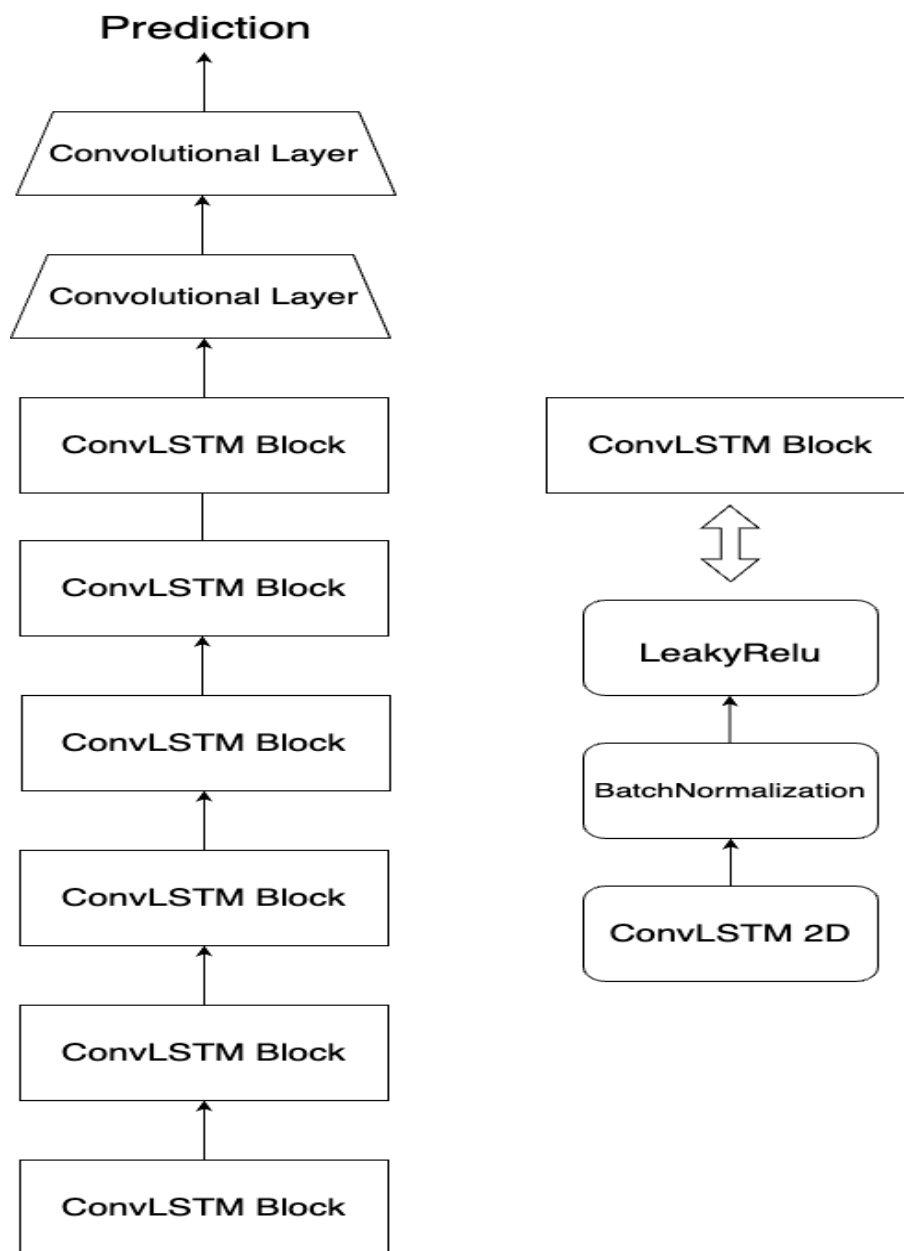


圖 2：本篇論文所使用之模型架構

本篇論文使用的模型架構為 ConvLSTM，對於本篇論文提出的模型架構圖(圖 2)中，對應到每一個使用的 ConvLSTM Block 皆由 ConvLSTM2D、BatchNormalization、LeakyRelu 所構成，並連續使用 6 個相同 ConvLSTM

Block 構建出模型前半部分，目的是處理時序的圖片資料，每個 Block 中的 ConvLSTM2D 之 units 數目依序為 128、64、32、16、8、1，其中每個 kernel size 皆為(3,3)，最後在模型輸出前在接兩層 Convolutional Layer，units 依序為 4、1，kernel size 為(3,3)、(1,1)，有助於產生較佳之數值圖片輸出。

第三章 資料與地震判定

3-1 GIMTEC 資料

GIMTEC(Global Ionosphere Map of Total Electron Content)的數據是通過全球定位系統 (GPS) 上的接收器進行測量和收集。當 GPS 訊號在穿越地球上層大氣時會受到電離層的影響，電子含量的分佈和分佈的變化會引起訊號的傳播延遲，利用這種延遲可以大約推算出地球上層 TEC 的分佈情況。GIMTEC 通常由多個國家和組織合作，在各國設立 GPS 接收器測量和收集數據，這些數據通常包括 GPS 接收器的位置、時間、訊號傳播延遲等相關訊息。通過分析可以生成全球範圍內的電離層 TEC 圖。藉此可以在科學研究機構、大學、研究中心等地方進行存取和分享。GIMTEC CODE (Center for Orbit Determination in Europe)利用 IGS (International GNSS Server)所提供之全球 200 個以上之 GPS 衛星接收站資料所繪製的 TEC 圖，如圖 3 所示。

本篇論文使用 CODEGIM 提供之 1999 年至 2021 年全球電離層全電子含量(GIMTEC)，時間解析度在 2014 年 10 月 19 日之前為兩小時一筆，往後至今為每小時為單位提供。其中空間解析度由北緯 -87.5° 至 87.5° ，間隔為

2.5°，經度由東經-180°至 180°，間隔 5°。每筆資料包含 TEC 值、資料的時間列表、資料點的緯度以及經度。




圖 3: TEC 範例圖

其中要注意的是，對於每有 GPS 測站的地方也有資料，是因為使用內插法讓其有值，故並不是每個點都是實際觀測值，對於特定區域的觀測值可能僅作參考。

3-2 電離層異常判定

在此我們使用一種顯示資料分布情形的統計圖表方法，稱之為盒式圖法 (Boxplot Method) 或稱箱形圖法，他透過將資料分成四個等份，從而反映出資料的中央趨勢、離散程度以及我們所在意異常值 (outlier)。

$$Upperbound = M + k(Q_3 - M) \quad (7)$$

$$Lowerbound = M - k(M - Q_1) \quad (8)$$

其中 Q_3 為第 3 四分位數、 Q_2 即 M 為中位數(Median)、 Q_1 為第 1 四分位數、 k (k value) 為 threshold。

所以在判斷電離層異常時，需要建立一個正常值的參考範圍，此時異常與否取決於是否超出或低於此範圍。這個範圍可以透過過去幾天的資料來構建參考背景，在此我們定義我們的參考背景為 15 天，以此為範圍構建參考背景。利用公式我們可以構建出正常範圍之上下界，超出正常值範圍我們稱之為正異常，低於正常值範圍我們則稱之為負異常，其他皆為正常值。

Liu et al. [2010] 論文指出，電離層全電子含量的數值為常態分佈 (Normal Distribution)，且當 k 值為 1.5 時，約略 68% 的資料會處在正常範圍內，且當 k 值增大時，門檻也會相對提高，故在本篇論文我們採用 k 值為 1.5 作為 threshold。

3-3 有地震、無地震的界定

本篇論文專注在預測規模 6 以上的地震，且有明顯的震前電離層異常之現象 (Pre-earthquake ionospheric anomaly, PEIA)，在此我們定義震前電離層異常為在地震發生前 5 天中 (120 小時) 內有超過 1/3 (40 小時) 是符合正異常的，因為規模 6 以上之地震通常較具有破壞力，而去預測出這些有足夠的異常表現為本篇論文的研究方向，從 1999 年 1 月 1 日至 2021 年 12 月 31 日之地震資料且有震前電離層異常之現象，總共有 46 筆。無地震的挑選為扣除那些地震日 (含其前 30 天)，因為模型在預測地震日為看完完整的 30 天才去做預測，須避免模型在訓練的時候誤將測試資料作為模型的輸入，導致不正確的結果，另外需扣除地震日後數天 (在此稱之為 Chaos days)，因為電離層有同震效應，在大地震或是火山爆發後可能有數天的電離層狀態不穩定，地震越大所隨之而來的電離層不穩定越明顯，在此我們定義我們所使用的 Chaos day 為 6.0~6.5 級為 5 天、6.5~7.0 級為 7 天、7.0~7.5 級為 10 天、7.5~8.0 為 15 天，因此不列入考慮，如圖 4 所示，紅圈所代表的是地震震央之位置，對應不同紅圈大小代表不同地震規模之地震，藍色三角形所標示的點為我們取用 TEC 觀測點的位置，以此位置上空 TEC 觀測值作為每筆地震資訊，圖 5 及圖 6 為所有地震及無地震對應時間的分佈圖。




圖 4: 自 1999 年 1 月 1 日至 2021 年 12 月 31 日所有規模大於 6 且有震前電離層異常的地震

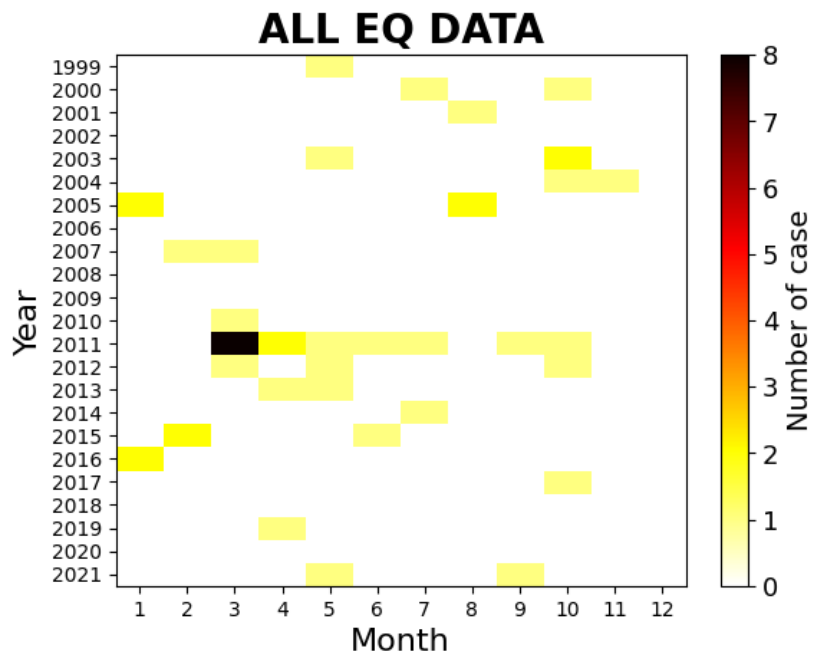


圖 5: 所有地震資料對應時間之分布圖

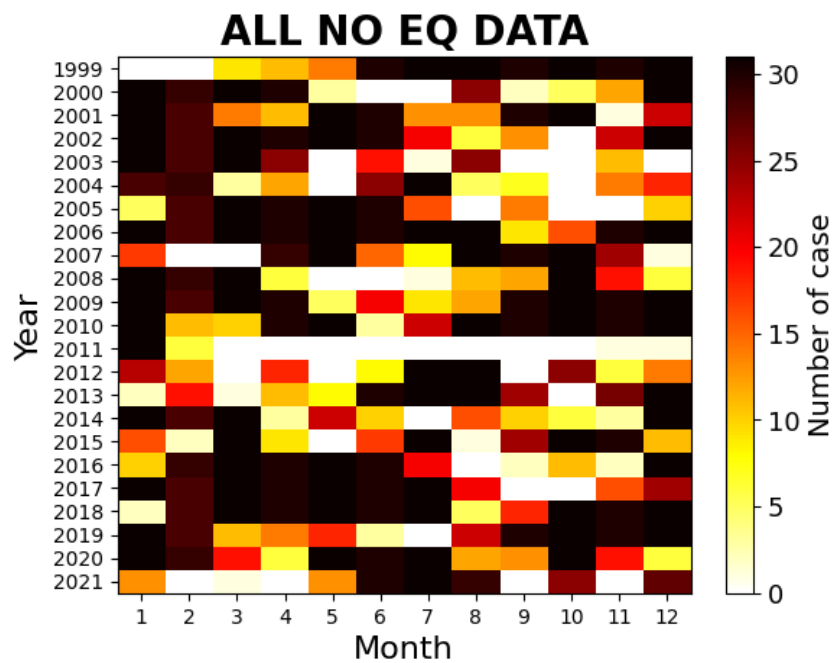


圖 6: 所有無地震資料對應時間之分布圖

第四章 實驗結果與討論

4-1 訓練資料、測試資料介紹

我們使用 1999 年 1 月 1 日至 2021 年 12 月 31 日之 GIMTEC 資料，對於 2014 年 10 月 19 日之前時間解析度為 2 小時之資料，我們使用內插法將其變為 1 小時一筆。對於每筆有地震或無地震，皆對應到一張 30×24 數值圖片，30 為地震或無地震前 30 天，24 為每天 24 小時之每小時 TEC 資料，由於使用的模型為 ConvLSTM2D，我們使用的 timestamps 為 7，原因是 Abdu et al. (2006) 發現赤道電噴流 (equatorial electro-jet, EEJ) 強度的功率譜，該譜在 ~ 6.5 和 ~ 14 天的周期性附近顯示出明顯的光譜峰，且 Tsai et al. (2022) 利用深度學習方法預測台灣規模 6 以上地震亦得到類似結果，因此選用 7 天當作模型的 timestamps，意義為看完 7 張 30×24 之圖片後去預測第下一張 30×24 的圖片，即利用前 7 天的資料去預測第 8 天資料，因此所對應模型的 input_shape 為 (Batch_size, 7(timestamps), 30, 24, 1)、而模型的 output_shape 為 (Batch_size, 30, 24, 1)，最後我們總共有 138330 筆的訓練、驗證資料(圖 7)。

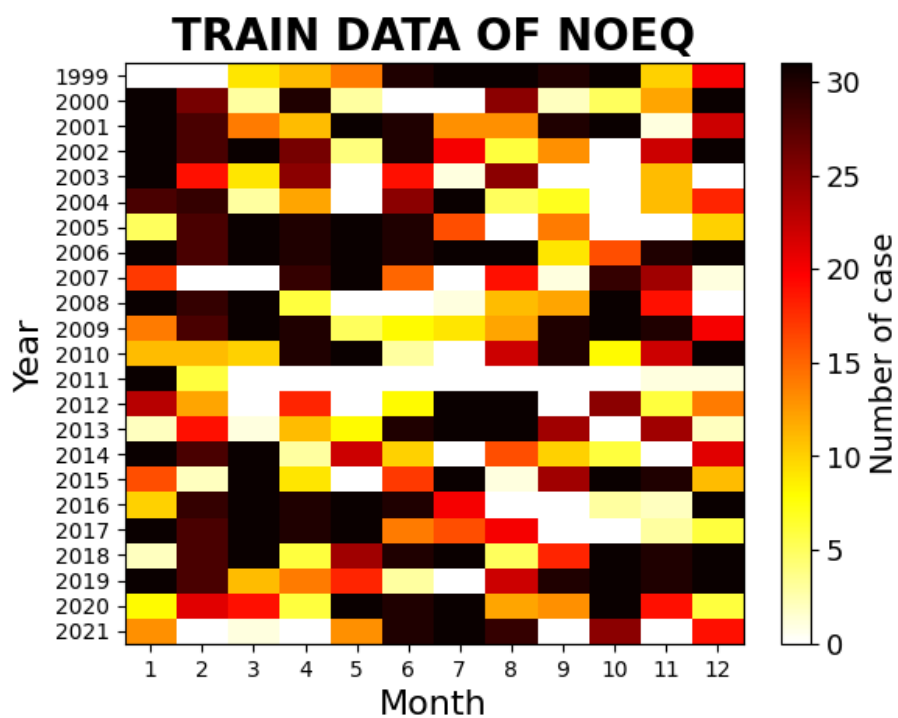


圖 7：所有無地震訓練資料對應時間之分布圖(實驗 1)

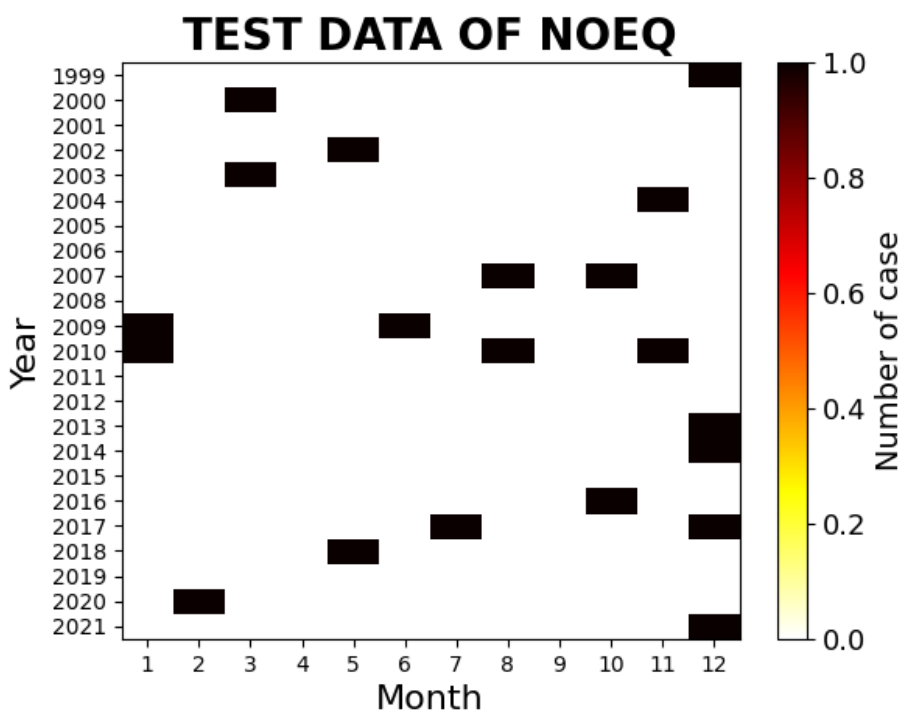


圖 8：所有無地震測試資料對應時間之分布圖(實驗 1)

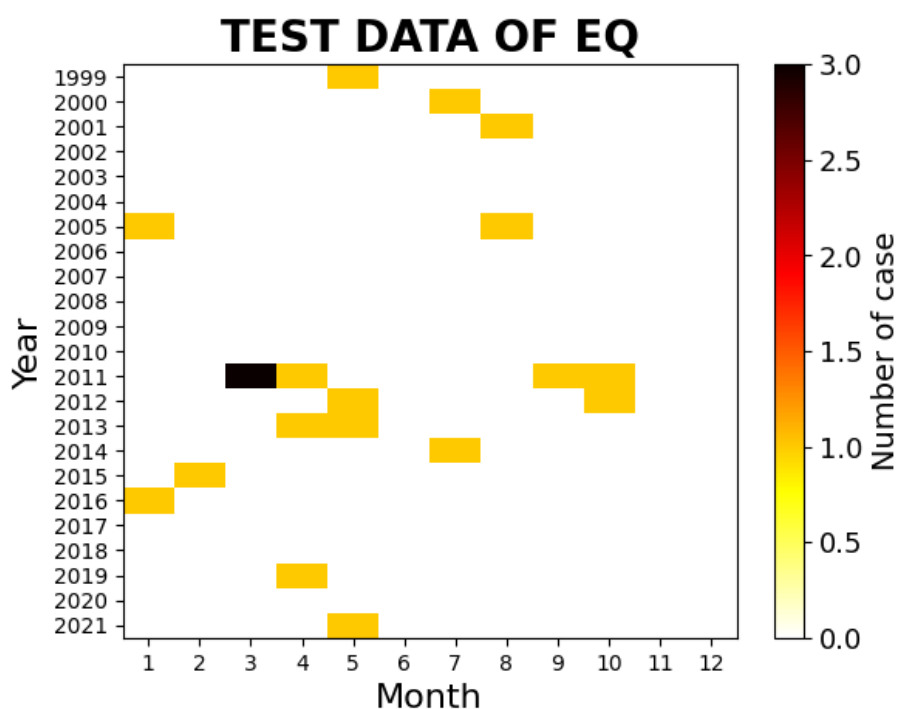


圖 9：所有地震測試資料對應時間之分布圖(實驗 1)

4-2 實驗說明

我們使用異常檢測的概念來訓練模型，模型在訓練時只訓練無地震的資料在此可以視為無地震資料為正常資料，所以對於模型而言他只學習過無地震的資料，當遇到測試的地震資料時，也就是異常資料，預測的結果跟實際結果就會有落差，然後利用這個誤差，再去訂立一個標準去區分它為有地震或是無地震。首先將我們的資料切割成訓練集、驗證集、測試集，我們先從有地震、無地震中各自選取 20 筆作為測試資料，全部的無地震資料扣除無地震的測試資料後(圖 8、圖 9)，再將選中的每筆無地震的測

試資料的前 30 日亦扣除，以防止模型訓練的時候作為輸入資料輸入，影響測試結果，訓練集與驗證集我們以 80%、20%的方式切割剩下之無地震的資料，訓練時我們設置 Batch size 為 32，總共訓練的 30 Epochs，使用 RMSE 作為我們的 Loss function，Learning rate 設置為 0.001，並採用 Adam 作為模型的優化器。以此配置針對實驗 1 的模型訓練 Loss 對應 Epoch 圖為圖 10 所示，我們以 Epoch 0 作為第 1 個 Epoch，共 30 個 Epoch(圖 10)。

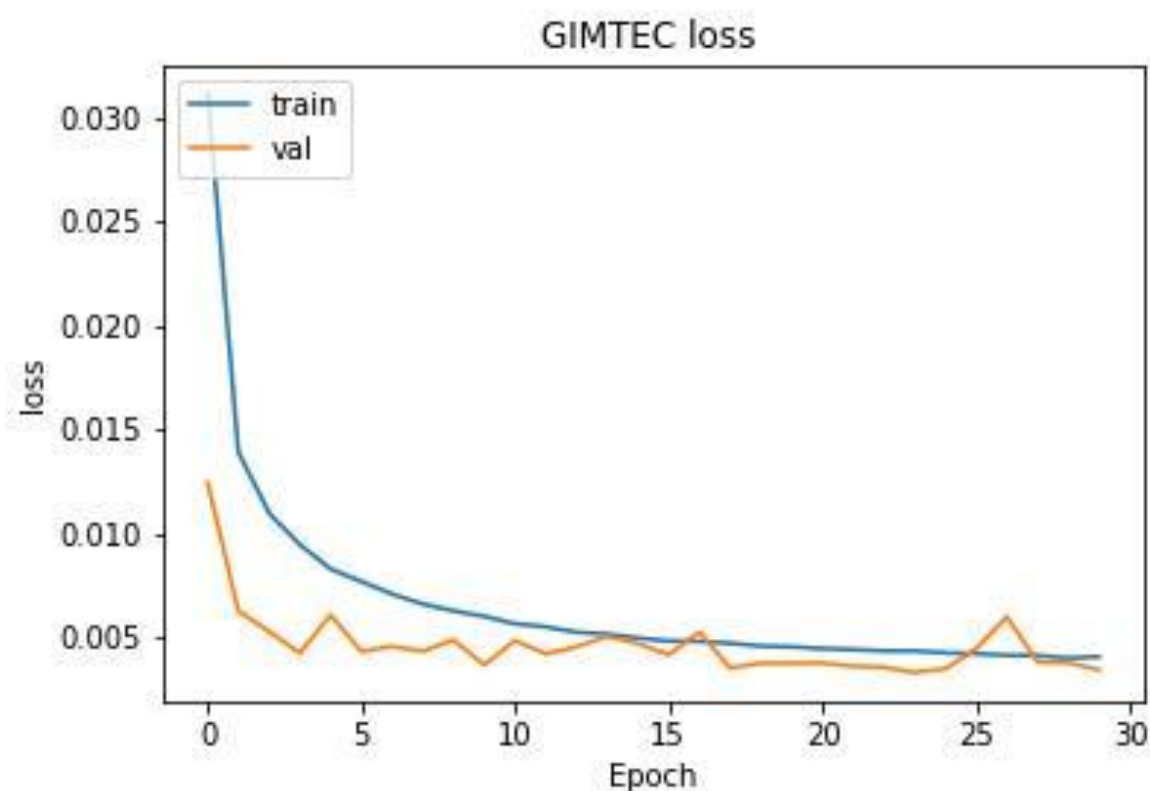


圖 10：模型訓練 Loss 對應 Epoch 圖(實驗 1)

4-3 異常判斷指標

模型訓練完後，由於我們設置的 `timestamps` 為 7，在預測出下一張的 30*24 的圖片時，我們只取最後一行的輸出（離地震日、無地震日最接近的那一天）中 24 小時 TEC 資料與真實的資料做 MSE 計算誤差，重複此操作至預測完完整的每筆地震前 30 日的 TEC 圖，並累加誤差，作為每筆測試資料最後的判斷依循，藉此再制定一套標準進行判斷，以決定是否為異常現象(地震即將發生)。

我們使用了三種評量方式來偵測異常現象的發生，第一種是以無地震測試資料中預測最差的樣本取其 MSE 值作為門檻，再來去區分每筆地震測試資料是否超過這個門檻，超過則歸類他為有異常現象發生，反之則為正常日。第二、三種為採用 Tsai et al.(2022)所提出的相對誤差的概念，將事件日之前 30 天拆成事件前 16~30 天、1~15 天，分別對應為 Stage1 及 Stage2，每個階段皆為 15 天的原因是，Wu et al. (2020)發現赤道電離異常 (Equatorial Ionization Anomaly, EIA) 的出現時間顯示了一個顯著的半月潮時間 (14.77 天)，表明地球電離層存在約 15 天的週期性變化，因此在測試資料的評量方式，將每筆測試資料拆成兩個階段，再使用相對誤差檢測異常，這麼做可以消除半月潮的影響，將其影響降至最低，另外季節性影響及太陽活動影響也能透過這個方式來降低，所以第二種我們使

用 MAE 來計算相對誤差，第三種則是使用 RMSE 來計算。在計算相對誤差可以藉由 Stage1 的 $(RMSE_1, MAE_1)$ 及 Stage2 的 $(RMSE_2, MAE_2)$ 來表示：

$$RE_{RMSE} = \left| \frac{RMSE_2 - RMSE_1}{RMSE_1} \right| \quad (9)$$

and

$$RE_{MAE} = \left| \frac{MAE_2 - MAE_1}{MAE_1} \right| \quad (10)$$

如何透過上述式子消除季節性影響，透過定義在分別 Stage1 及 Stage2 的季節性影響為 $RMSE_{sea1}$ 及 $RMSE_{sea2}$ ，另外在 Stage2 中可能持有的地震電離層異常為 $RMSE_{eqk2}$ 表示成：

$$RE_{RMSE} = \left| \frac{RMSE_{sea2} + RMSE_{eqk2} - RMSE_{sea1}}{RMSE_{sea1}} \right|, RMSE_{sea1} \approx RMSE_{sea2} \quad (11)$$

透過上述式子我們可以消除季節性的影響使其最後剩下 $RMSE_{eqk2}$ ，並計算出相對誤差後，透過定義門檻 (Threshold)，在此我們設定門檻為 30%，如果計算出來的相對誤差超過這個門檻我們視為異常現象要發生，反之為正常現象。

4-4 實驗結果

表格 1 為獨立的 10 次實驗，每一次皆是重新訓練整個模型，採用相同的模型參數，並且皆使用三種的測試評量方式來得到實驗結果，測試資料集為各 20 筆的有地震、無地震資料，相較於無地震，有地震的資料相對較少，可以使用的有地震僅僅只有 46 筆(地震規模 6 以上且有過我們設定的 PEIA 標準)，為了最後計算準確度的公平性，我們隨機從兩者中分別隨機取出 20 筆出來作為測試資料。由這 10 次實驗我們使用無地震最大 MSE 作為門檻所得到平均準確度為 82.75%，而使用 Tsai et al.(2022)所提出的相對誤差方式，另外我們自己定義門檻為 30%，最後我們得到的 RelativeError MAE 及 RelativeError RMSE 所得到平均準確度為 62.75%、63.25。在此我們討論實驗 1 的結果，因為實驗 1 所得到的 Max NoEQ MSE 之準確度為 82.5%，較接近我們 10 次實驗所求得平均準確度，所得實驗結果為表 1、表 2 及表 3。。

其中我們討論 2000 年 7 月 20 日所發生的地震規模 6 的地震（圖 11），我們以 3 種方式去觀察，第一種使用預測值與實際值之間的絕對誤差：

$$\text{誤差} = |\text{預測值} - \text{實際值}|$$

的方式來直接觀察預測數值圖與實際數值圖的關係，第二、三種方式我們採用相對誤差的概念，分別為：

$$Relative\ Difference = (預測值 - 實際值) / 實際值 \quad (12)$$

和

$$Absolute\ Relative\ Difference = |預測值 - 實際值| / 實際值 \quad (13)$$

可以發現不管是哪一種方式我們都可以在地震發生前的第 23 天(縱軸座標 -23 處，對應日期為 6 月 27 日)皆存在預測與實際值存在較大的落差之處，我們根據 Final Dst Index (圖 12)，可以觀察到在 6 月 26 日那天有較高機率發生磁暴，受到磁暴的影響有明顯的 TEC 變化，但在 6 月 27 日所實際觀察到的 TEC 數值卻相對低，然而模型所預測出來的值受到 6 月 26 日數值的影響而在 6 月 27 日預測了較高的數值，導致出現了數值落差，在此我們推測這裡存在地震電離層前兆的資訊。

表 1：使用本篇論文模型架構分別獨立訓練 10 次的測試實驗結果

	Max NoEQ MSE(%)	RelativeError MAE(%)	RelativeError RMSE(%)
Experiment 1	82.5	65	67.5
Experiment 2	80	72.5	65
Experiment 3	82.5	62.5	60
Experiment 4	87.5	60	65
Experiment 5	82.5	55	57.5
Experiment 6	85	57.5	57.5
Experiment 7	80	60	62.5
Experiment 8	87.5	62.5	60
Experiment 9	75	65	72.5
Experiment 10	85	67.5	65
Average Accuracy	82.75	62.75	63.25

表 2：對應實驗結果 1(Experiment 1)之 20 筆地震測試資料預測結果

	MSE Error	EQ Date	Magnitude
1	147.14*1e-5	2012/5/20	6.3
2	129.59*1e-5	2000/7/20	6
3	123.23*1e-5	2014/7/11	6.5
4	57.90*1e-5	2011/10/21	6.1
5	54.45*1e-5	2011/9/15	6.1
6	53.43*1e-5	1999/5/12	6.2
7	50.69*1e-5	2011/4/13	6
8	47.97*1e-5	2011/3/14	6
9	47.37*1e-5	2011/3/13	6.1
10	45.67*1e-5	2011/3/12	6.5
11	37.06*1e-5	2012/10/1	6.1
12	34.29*1e-5	2016/1/14	6.7
13	26.50*1e-5	2021/5/13	6
14	23.88*1e-5	2013/5/18	6
15	22.54*1e-5	2005/8/30	6.1
16	21.10*1e-5	2001/8/13	6.4
<u>17</u>	19.00*1e-5	2015/2/20	6.2
18	14.95*1e-5	2013/4/1	6
19	13.38*1e-5	2005/1/19	6.6
20	8.66*1e-5	2019/4/11	6

表格 3: 對應實驗結果 1(Experiment 1)之 20 筆無地震測試資料預測結果

	MSE Error	NoEQ Date
1	24.42*1e-5	2018/5/7
2	22.89*1e-5	2002/5/27
3	19.83*1e-5	2004/11/19
4	19.06*1e-5	2000/3/28
5	16.22*1e-5	2016/10/8
6	15.66*1e-5	2021/12/12
7	14.37*1e-5	1999/12/11
8	14.17*1e-5	2003/3/22
9	12.34*1e-5	2014/12/10
10	11.74*1e-5	2017/12/18
11	11.48*1e-5	2007/10/2
12	11.08*1e-5	2010/11/8
13	10.77*1e-5	2007/8/12
14	10.49*1e-5	2010/8/9
15	9.65*1e-5	2020/2/8
16	9.37*1e-5	2017/7/15
<u>17</u>	8.81*1e-5	2013/12/29
18	8.68*1e-5	2009/6/22
19	8.13*1e-5	2009/1/17
20	6.24*1e-5	2010/1/20

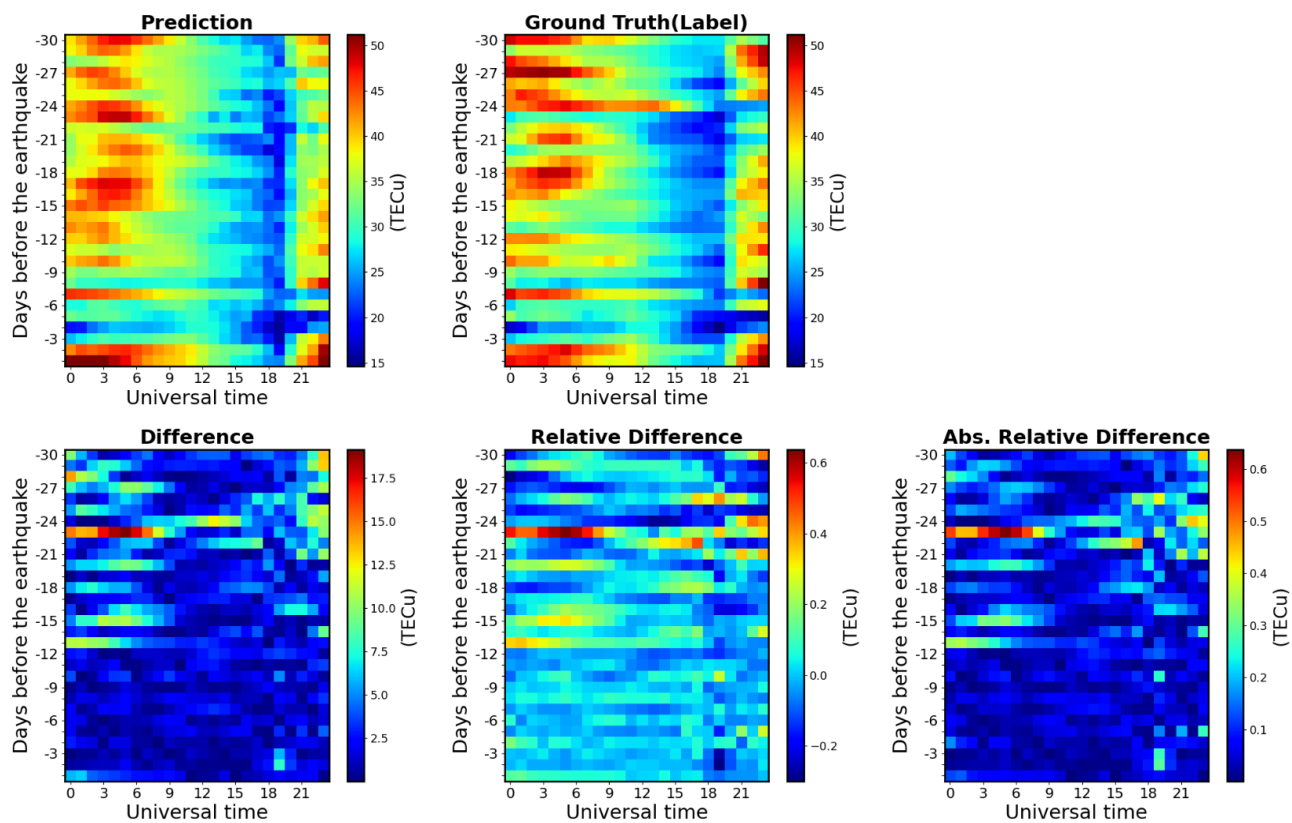


圖 11: 2000 年 7 月 20 日之地震測試資料結果圖




圖 12: 2000 年 6 月之 Final Dst Index 數值圖

第五章 結論

本篇論文為使用深度學習方法之模型來預測地震規模 6 以上較大規模且具有我們定義的地震電離層異常的地震，著重於預測出跟電離層異常較相關的異常地震，在此透過使用無地震測試資料中最大 MSE 作為我們的門檻得到了平均 82.75% 的準確度，且使用無地震測試資料中最大 MSE 作為門檻的方式少了較多人為控制的因素，可以較明確。

使用 ConvLSTM 模型相較於傳統 LSTM 模型而言，利用滑動窗口的概念，可處理二維的空間訊息，在本篇論文所使用的資料便可以透過滑動窗口來收集不同天、不同小時之時序資料資訊來獲得較準確的結果，而傳統 LSTM 模型只能透過一維資料，少了直接從空間上獲取資訊的方式。

參考文獻

- [1] Tsai, T. C., Jhuang, H. K., Ho, Y. Y., Lee, L. C., Su, W. C., Hung, S. L., ... & Kuo, C. L. (2022). Deep learning of detecting ionospheric precursors associated with $M \geq 6.0$ earthquakes in Taiwan. *Earth and Space Science*, 9(9), e2022EA002289.
- [2] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural computation*, 9(8), 1735-1780.
- [3] Shi, X., Chen, Z., Wang, H., Yeung, D. Y., Wong, W. K., & Woo, W. C. (2015). Convolutional LSTM network: A machine learning approach for precipitation nowcasting. *Advances in neural information processing systems*, 28.
- [4] Abdu, M. A., Ramkumar, T. K., Batista, I. S., Brum, C. G. M., Takahashi, H., Reinisch, B. W., & Sobral, J. H. A. (2006). Planetary wave signatures in the equatorial atmosphere–ionosphere system, and mesosphere-E-and F-region coupling. *Journal of Atmospheric and Solar-Terrestrial Physics*, 68(3-5), 509-522.
- [5] Wu, T. Y., Liu, J. Y., Lin, C. Y., & Chang, L. C. (2020). Response of ionospheric equatorial ionization crests to lunar phase. *Geophysical Research Letters*, 47(7), e2019GL086862.

- [6] Liu, J. Y., Chen, Y. I., Pulinets, S. A., Tsai, Y. B., & Chuo, Y. J. (2000). Seismo-ionospheric signatures prior to $M \geq 6.0$ Taiwan earthquakes. *Geophysical research letters*, 27(19), 3113-3116.
- [7] Liu, J. Y., Chen, Y. I., Chuo, Y. J., & Tsai, H. F. (2001). Variations of ionospheric total electron content during the Chi-Chi earthquake. *Geophysical Research Letters*, 28(7), 1383-1386.
- [8] Liu, J. Y., Chen, Y. I., Chuo, Y. J., & Chen, C. S. (2006). A statistical investigation of preearthquake ionospheric anomaly. *Journal of Geophysical Research: Space Physics*, 111(A5).
- [9] Jhuang, H. K., Ho, Y. Y., Kakinami, Y., Liu, J. Y., Oyama, K. I., Parrot, M., ... & Zhang, D. (2010). Seismo-ionospheric anomalies of the GPS-TEC appear before the 12 May 2008 magnitude 8.0 Wenchuan Earthquake. *International Journal of Remote Sensing*, 31(13), 3579-3587.
- [10] GIMTEC Dataset: 取自
<https://scidm.nchc.org.tw/dataset/earthquake-and-tsunami>
- [11] 地震資訊: 取自
<https://www.usgs.gov/programs/earthquake-hazards>

[12] Aji, B. A. S., Liong, T. H., & Muslim, B. (2017, October). Detection precursor of sumatra earthquake based on ionospheric total electron content anomalies using N-Model Artificial Neural Network. In *2017 International Conference on Advanced Computer Science and Information Systems (ICACISIS)* (pp. 269-276). IEEE.